

Gerador de Dataset Sintético de Pacientes para Pesquisa em Inteligência Artificial

Relatório técnico: arquitetura, modelo de geração, cálculos, validação de qualidade e privacidade, experimentos de aprendizado de máquina e comparação com base pública real

Autora: Judith Otavia Margarido de Andrade
Projeto acadêmico de mestrado
02/10/2026

DATASET SINTÉTICO — NÃO CONTÉM DADOS REAIS DE PACIENTES
O dataset principal é inteiramente sintético. A base real usada para comparação (UCI Heart Disease) é pública, anonimizada na origem e mantida separada.

Repositório: <https://github.com/judithotavia-ux/dataset-sintetico-pacientes> · versão do dataset 1.0.0 · gerador 1.0.0

Sumário

1. Resumo
2. Objetivo, escopo e restrições
3. Arquitetura do sistema
4. Modelo de geração e cálculos
5. Validação de qualidade
6. Privacidade: `privacy_guard`
7. Dataset de exemplo: resultados descritivos
8. Experimentos de aprendizado de máquina
9. Base pública real e comparação
10. Testes automatizados
11. Reprodutibilidade
12. Limitações e riscos
13. Referências

1. Resumo

Este relatório documenta o desenvolvimento de uma aplicação local que gera, valida e exporta um **dataset sintético de pacientes** para testes, treinamento e validação de sistemas de Inteligência Artificial em uma pesquisa de mestrado. Nenhum dado real de paciente é usado na geração: os registros seguem um modelo estatístico causal simplificado, definido pela autora, com aleatoriedade controlada por um único *seed*, o que torna cada dataset exatamente reproduzível.

A aplicação gera 100, 1.000, 10.000 ou 100.000 pacientes com 50 variáveis: demografia, antropometria, sinais vitais, histórico familiar, hábitos, condições clínicas, medicamentos, 8 exames laboratoriais, escore e classe de risco, diagnóstico e desfecho em 12 meses. O backend usa Python/FastAPI/SQLite, e o painel usa React/TypeScript. A camada **privacy_guard** bloqueia campos de identificação pessoal e impede exportações não conformes. O particionamento treino/validação/teste (70/15/15) é estratificado e reproduzível.

Com 10.000 pacientes (*seed* 42), modelos de referência atingem ROC-AUC de 0,794 na previsão de desfecho adverso, macro-F1 de 0,775 na classificação de risco e R^2 de 0,508 na regressão da pressão sistólica, todos muito acima das baselines ingênuas. Isso mostra que o dataset contém estrutura aprendível, sem ser trivial.

Para comparação, foi incluída, em separado, a base pública real **UCI Heart Disease — Cleveland** (303 pacientes, CC BY 4.0). Nela, a regressão logística obtém ROC-AUC de $0,910 \pm 0,032$ para doença cardíaca. Os testes automatizados somam 186 casos (186 aprovados, nenhuma falha).

2. Objetivo, escopo e restrições

Objetivo. Disponibilizar um conjunto de dados clínicos simulados, plausível do ponto de vista estatístico e adequado a experimentos de classificação, regressão, detecção de padrões e análise exploratória. O conjunto deve dispensar o acesso a prontuários reais na fase de desenvolvimento da pesquisa.

Restrições de privacidade adotadas desde o início (*privacy by design*):

- nenhum dado real de paciente, sem scraping de prontuários, hospitais ou redes sociais;
- nenhum registro copia, reconstrói ou adapta uma pessoa real;
- nenhum identificador: o sistema não tem campos de nome, CPF, RG, CNS, prontuário, telefone, e-mail, endereço ou data de nascimento;
- todo registro tem as marcações `data_type = "SYNTHETIC"` e `research_only = true`;
- o sistema não oferece função de importar dados pessoais reais. O uso de dados reais exige uma etapa própria de governança (CEP, base legal da LGPD).

Tecnologias. Python 3.12, FastAPI, SQLAlchemy, SQLite, Pydantic, Faker, Pandas, NumPy, scikit-learn; React, Vite, TypeScript, Tailwind CSS e Recharts no painel; pytest para os testes; Docker opcional.

3. Arquitetura do sistema

O código foi organizado por responsabilidade. Um **dicionário de dados** único (`dataset_schema.py`) define as 50 variáveis: tipo, unidade, faixa válida, categorias e papel em ML. O gerador, a validação, os metadados e a Dataset Card consultam esse mesmo dicionário, o que evita inconsistências.

Módulo	Responsabilidade
generator.py	Geração dos pacientes (modelo causal, seed, partição estratificada)

Módulo	Responsabilidade
quality.py	Validações de qualidade e relatório
privacy_guard.py	Deteção e bloqueio de dados pessoais; validate_privacy(dataset)
exporter.py	Exportação CSV, XLSX, JSON e Parquet (sempre após o privacy_guard)
metadata.py	metadata.json e Dataset Card
repository.py / models.py	Persistência normalizada em 6 tabelas e reconstrução da tabela plana
audit.py	Logs técnicos de auditoria (sem dados pessoais)
public_datasets.py	Base pública real UCI Heart Disease, separada do sintético
main.py	API REST (FastAPI) consumida pelo painel React


3.1 Modelo de banco de dados

Tabela	Cardinalidade	Conteúdo
dataset_metadata	1 por dataset	id, versão, seed, nº de registros, status (ATIVO/SUBSTITUÍDO), resultados de validação, metadata JSON
patients	1 por paciente	demografia, antropometria, histórico familiar, hábitos, partição, marcações
clinical_records	1 por paciente	data do atendimento, sinais vitais, condições, aderência, risco, diagnóstico, desfecho
lab_results	8 por paciente	exame, valor, unidade, data de coleta (formato longo)
medications	0 a N por paciente	ordem, nome, classe terapêutica, posologia
audit_logs	1 por evento	data, evento, nível, dataset, detalhes técnicos

Um teste automatizado garante que a gravação nas tabelas normalizadas seguida da reconstrução da tabela plana devolve exatamente o mesmo conjunto de dados. Quando um novo dataset é gerado, o anterior é removido na mesma transação e fica registrado como SUBSTITUÍDO.

3.2 Fluxo da aplicação

Geração: painel → POST /api/datasets/generate (validação Pydantic com extra="forbid") → gerador → validação de qualidade → validação de privacidade → gravação nas 6 tabelas → metadata.json, Dataset Card e relatórios. Exportação: painel → GET /api/export/{formato} → privacy_guard → arquivo. Se alguma validação falhar, o fluxo é interrompido e o evento é auditado.



4. Modelo de geração e cálculos

O gerador segue a cadeia causal abaixo. Em cada etapa entra ruído aleatório, como em dados observacionais. Os coeficientes foram escolhidos para produzir valores plausíveis. Eles **não** foram estimados de uma população real e não devem ser interpretados como evidência clínica. Nas equações, o separador decimal é o ponto, igual ao código-fonte.

idade, sexo, hábitos, histórico familiar → IMC → condições clínicas → tratamento e aderência → sinais vitais e exames → escore de risco → classificação de risco → desfecho em 12 meses

Notação. $\sigma(z)$ é a função logística; $N(\mu, s^2)$ é a distribuição normal; $Bern(p)$ é a distribuição de Bernoulli; variáveis indicadoras valem 1 quando a condição é verdadeira: S = sedentário, A = fisicamente ativo, F = fumante atual, E = consumo elevado de álcool, D_r/D_b = dieta ruim/boa, HAS = hipertensão, DM = diabetes tipo 2, DLP = dislipidemia, OB = obesidade, DRC = doença renal crônica, IRA = infecção respiratória aguda. $T_c = 1$ se a condição c é tratada; e = efeito da aderência ao tratamento.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

4.1 Demografia, histórico familiar e hábitos

idade $\sim \mathcal{N}(48, 17^2)$ truncada em $[18, 90]$ (por reamostragem), sexo = F com $p = 0.51$. A truncagem por reamostragem sorteia de novo os valores fora do intervalo, em vez de cortá-los, para não acumular massa nos limites. O município é sorteado entre 120 nomes **inventados** (prefixo + radical + sufixo, por exemplo "Vale de Aurival"), cada um associado a uma UF.

Variável	Distribuição
Histórico familiar	Bern(0.25) diabetes; Bern(0.35) hipertensão; Bern(0.18) doença cardiovascular
Tabagismo	nunca / ex / atual = 0.66 / 0.18 / 0.16 (masculino: 0.61 / 0.18 / 0.21)
Álcool	nenhum / moderado / elevado = 0.45 / 0.43 / 0.12 (masculino: 0.39 / 0.43 / 0.18)
Atividade física	$p(\text{sedentário}) = \text{clip}(0.30 + 0.005(\text{idade}-18); 0.30; 0.65)$; $p(\text{ativo}) = \text{clip}(0.30 - 0.003(\text{idade}-18); 0.10; 0.30)$
Dieta	ruim / regular / boa = 0.25 / 0.50 / 0.25
Horas de sono	$\text{clip}(N(7.0; 1.1^2); 4; 10)$

4.2 Antropometria e IMC

$$h \text{ (cm)} \sim \mathcal{N}(172, 7^2) \text{ (M)}, \quad \mathcal{N}(160, 6.5^2) \text{ (F)}, \quad \text{clip} [145, 200]$$

$$\text{IMC}^* = 24.0 + 0.07 (\min(\text{idade}, 65) - 40) + 1.6S - 1.3A + 1.3D_r - 0.9D_b + 0.6E + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 4^2)$$

$$\text{peso} = \text{IMC}^* \cdot \left(\frac{h}{100}\right)^2 \quad \text{IMC} = \frac{\text{peso}}{(h/100)^2}$$

O IMC latente é limitado a $[16.5; 48]$ e o peso a $[38; 180]$ kg. O IMC final é **recalculado** a partir do peso e da altura já arredondados, para que a variável publicada seja sempre coerente com a fórmula (tolerância de 0,05 kg/m² na validação). Exemplo: 70 kg e 175 cm dão $70 / 1.75^2 = 22.86$ kg/m².

4.3 Condições clínicas: modelos logísticos

Cada condição crônica segue $P(\text{condição} = 1 \mid x) = \sigma(\beta_0 + \beta^T x)$, com sorteio de Bernoulli independente. Coeficientes:

Condição	Preditor linear (logit)
Hipertensão	$-5.2 + 0.065 \cdot \text{idade} + 0.09(\text{IMC}-25) + 0.7 \cdot \text{HF}_{\text{HAS}} + 0.35F + 0.3E + 0.25S$
Diabetes tipo 2	$-5.6 + 0.045 \cdot \text{idade} + 0.13(\text{IMC}-25) + 0.9 \cdot \text{HF}_{\text{DM}} + 0.35S + 0.3D_r$
Dislipidemia	$-3.6 + 0.035 \cdot \text{idade} + 0.07(\text{IMC}-25) + 0.4D_r + 0.3 \cdot \text{HF}_{\text{DCV}}$

Condição	Preditor linear (logit)
Asma	$-2.6 + 0.3F$
Doença renal crônica	$-7.5 + 0.05 \cdot \text{idade} + 1.0 \cdot \text{DM} + 0.8 \cdot \text{HAS}$
Obesidade	determinística: $\text{IMC} \geq 30$ (classificação da OMS)
Infecção respiratória aguda	$\text{Bern}(0.07 + 0.03F)$, condição aguda (com febre)

A **condição principal** é a de maior prioridade presente ($\text{DRC} > \text{DM2} > \text{HAS} > \text{IRA} > \text{DLP} > \text{OB} > \text{asma}$). Sem nenhuma, ela é SEM_CONDICAO_CRONICA. Exemplo: um paciente de 60 anos com IMC 30, histórico familiar de hipertensão e não fumante tem $\text{logit} = -5.2 + 3.9 + 0.45 + 0.7 = -0.15$, ou seja, $P(\text{HAS}) = \sigma(-0.15) \approx 0.46$.

4.4 Tratamento e aderência

Cada condição tratável recebe tratamento com probabilidade $P(T_c = 1 \mid \text{condição}) = 0,80$ (HAS), 0,85 (DM2), 0,60 (DLP), 0,75 (asma) e 0,90 (IRA). Os medicamentos vêm de um catálogo simulado por condição (ex.: losartana, metformina, sinvastatina). Se houver tratamento, a aderência é sorteada como alta/média/baixa com probabilidades 0,55/0,30/0,15 e define o efeito do tratamento:

Aderência	alta	média	baixa	sem tratamento
Efeito e	1,00	0,55	0,15	0

4.5 Sinais vitais

$$\text{PAS} = 112 + 0.35(\text{idade} - 40) + 0.7(\text{IMC} - 25) + 18 \text{HAS} + 3F + 2E \\ + 4 \text{DRC} - 12 T_{\text{HAS}} e + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 10^2)$$

$$\text{PAD} = \min(\text{clip}(0.5 \text{PAS} + 12 + 0.2(\text{IMC} - 25) + \varepsilon, 50, 125), \text{PAS} - 20), \quad \varepsilon \sim \mathcal{N}(0, 6^2)$$

$$\text{FC} = 72 + 4S - 5A + 3F + 15 \text{IRA} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 9^2)$$

$$T (^{\circ}\text{C}) = 36.6 + \varepsilon_1 + \text{IRA}(1.8 + \varepsilon_2)$$

A PAS é limitada a [85; 215] mmHg e a FC a [45; 150] bpm; $\varepsilon_1 \sim \mathcal{N}(0; 0,3^2)$ e $\varepsilon_2 \sim \mathcal{N}(0; 0,5^2)$. A PAD é forçada a ficar pelo menos 20 mmHg abaixo da PAS, o que garante coerência fisiológica (diastólica < sistólica).

4.6 Exames laboratoriais

$$G \mid \text{DM} \sim \mathcal{N}(160, 35^2) - 30 T_{\text{DM}} e \quad G \mid \text{sem DM} \sim \mathcal{N}(90 + 0.25(\text{IMC} - 25), 9^2)$$

$$\text{HbA1c} = \frac{G + 46.7}{28.7} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 0.35^2)$$

A relação entre HbA1c e glicose é a inversa da fórmula do estudo ADAG (glicose média estimada = $28,7 \times \text{HbA1c} - 46,7$), aplicada aqui à glicemia de jejum como simplificação.

$$\text{CT} = 185 + 0.4(\text{idade} - 40) + 35 \text{DLP} - 30 T_{\text{DLP}} e + 6D_r + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 28^2)$$

$$\text{HDL} = \{47 \text{ (M)}; 56 \text{ (F)}\} - 4S - 3 \text{OB} + 5A + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 9^2)$$

$$\text{TG} = 110 \cdot \exp(0.03(\text{IMC} - 25) + 0.35 \text{DLP} + 0.25 \text{DM} + \varepsilon), \quad \varepsilon \sim \mathcal{N}(0, 0.35^2)$$

$$\text{LDL} = \text{CT} - \text{HDL} - \frac{\text{TG}}{5} \text{ se } \text{TG} < 400 \text{ (Friedewald)}; \quad \text{LDL} = 0.75 (\text{CT} - \text{HDL}) \text{ se } \text{TG} \geq 400$$

$$\text{Cr} = \{0.95 \text{ (M)}; 0.75 \text{ (F)}\} + 0.004(\text{idade} - 40) + \text{DRC} \cdot \mathcal{N}(1.0, 0.4^2) + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 0.12^2)$$

$$\text{Hb} = \{14.8 \text{ (M)}; 13.2 \text{ (F)}\} - 1.0 \text{DRC} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 1)$$

A equação de Friedewald perde validade com triglicerídeos ≥ 400 mg/dL. Nesse caso, usa-se uma aproximação alternativa. Exemplo: $\text{CT} = 220$, $\text{HDL} = 45$ e $\text{TG} = 150$ dão $\text{LDL} = 220 - 45 - 30 = 145$ mg/dL.

4.7 Escore de risco sintético, classificação e desfecho

$$z = 0.055(\text{idade} - 50) + 0.028(\text{PAS} - 130) + 0.6F + 0.8\text{DM} + 0.010(\text{CT} - 200) - 0.025(\text{HDL} - 50) \\ + 1.0\text{DRC} + 0.04(\text{IMC} - 27) + 0.4\text{HF}_{\text{DCV}} + 0.6\mathbf{1}[T \geq 38.5] + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, 0.35^2) \\ \text{escore} = 100 \cdot \sigma(z - 1.4) \in [0, 100]$$

Escore	< 10	10 a < 20	20 a < 40	≥ 40
Classe	BAIXO	MODERADO	ALTO	MUITO_ALTO

O escore é uma construção sintética e **não** equivale a escores clínicos validados. O desfecho em 12 meses segue dois estágios: primeiro se há desfecho adverso, depois o tipo.

$$P(\text{adverso}) = \sigma(-3.6 + 0.045 \text{escore} + 0.9\text{DRC} + 0.6\mathbf{1}[\text{aderencia baixa}] + 0.5\text{IRA} + \varepsilon) \\ \varepsilon \sim \mathcal{N}(0, 0.5^2)$$

$$p_{\text{CV}} = \text{clip}(0.20 + 0.004(\text{PAS} - 130) + 0.15\text{DM}; 0.05; 0.60)$$

$$p_{\text{óbito}} = \text{clip}(0.02 + 0.0025(\text{idade} - 50) + 0.05\text{DRC}; 0.01; 0.25)$$

Se houver desfecho adverso, o tipo é evento cardiovascular (p_{CV}), óbito ($p_{\text{óbito}}$) ou internação ($1 - p_{\text{CV}} - p_{\text{óbito}}$). A variável binária desfecho_adverso indica qualquer desfecho diferente de SEM_INTERCORRENCIA.

4.8 Particionamento treino/validação/teste

A partição é estratificada pela classificação de risco. Para cada classe k com n_k pacientes, os índices são embaralhados com um gerador derivado do seed (seed + 7919) e divididos assim:

$$n_k^{\text{treino}} = \text{round}(0.70 n_k), \quad n_k^{\text{valid}} = \text{round}(0.15 n_k), \quad n_k^{\text{teste}} = n_k - n_k^{\text{treino}} - n_k^{\text{valid}}$$

4.9 Identificadores e reprodutibilidade

O patient_id segue o padrão SYN- + 16 dígitos hexadecimais, tirados de um UUID4 gerado pelo Faker com seed. Ele não tem relação com nenhum documento, e a unicidade é garantida por reamostragem. Toda a aleatoriedade vem de `numpy.random.default_rng(seed)` (PCG64) e de `Faker.seed_instance(seed)`. Um teste automatizado confirma que o mesmo seed reproduz o mesmo dataset de forma idêntica.

5. Validação de qualidade

A função `validate_quality(df)` executa 8 grupos de verificações e reprova o dataset a qualquer erro. Cada regra tem um teste automatizado que injeta o defeito correspondente e confirma a detecção.

Verificação	Regra
Colunas obrigatórias	as 50 colunas do dicionário presentes
Valores ausentes	nenhum nulo ou texto vazio (exceto medicamentos, em que vazio significa nenhum)
Tipos de dados	int/float/bool/texto conforme o dicionário; datas no formato AAAA-MM-DD
Intervalos e categorias	valores dentro de [mín, máx] (tabela abaixo); categorias pertencentes ao domínio
IMC	$ \text{IMC} - \text{peso}/(\text{altura}/100)^2 \leq 0,05 \text{ kg/m}^2$
Pressão arterial	PAD < PAS em todos os registros, e PAS/PAD dentro das faixas
Identificadores	patient_id único e no padrão SYN-XXXXXXXXXXXXXXXXXX
Consistência interna	obesidade $\Leftrightarrow$ IMC ≥ 30 ; desfecho_adverso $\Leftrightarrow$ resultado $\neq$ SEM_INTERCORRENCIA; n_medicamentos = itens da lista

Faixas de plausibilidade das variáveis numéricas (valores fora delas são considerados impossíveis):

Variável	Unidade	Mínimo	Máximo
idade	anos	18	90
peso_kg	kg	35	200
altura_cm	cm	140	205
imc	kg/m ²	12	70
pa_sistolica	mmHg	70	250
pa_diastolica	mmHg	40	150
frequencia_cardiaca	bpm	30	200
temperatura_c	°C	34,0	42,0
horas_sono	h	3	12
n_condicoes	—	0	7
n_medicamentos	—	0	10
glicemia_jejum	mg/dL	40	600
hba1c	%	3,5	16
colesterol_total	mg/dL	80	450
ldl	mg/dL	20	350
hdl	mg/dL	15	130
triglicerides	mg/dL	20	1.500
creatinina	mg/dL	0,2	12
hemoglobina	g/dL	6	21
escore_risco	pontos	0	100

Resultado no dataset de exemplo (n = 1000, seed 42): colunas obrigatorias = OK; valores ausentes = OK; tipos de dados = OK; intervalos e categorias = OK; imc = OK; pressao arterial = OK; identificadores = OK; consistencia interna = OK. O dataset de 10.000 pacientes também foi aprovado (APROVADO).

6. Privacidade: privacy_guard

A função `validate_privacy(dataset)` devolve `{"compliant": bool, "blocked_fields": [...], "warnings": [...]}`. Ela atua em quatro pontos: na entrada da API, antes de gravar, antes de exportar e sob demanda no botão Validar Privacidade. Os alertas e a auditoria registram apenas nomes de campos, categorias e contagens, nunca valores.

6.1 Bloqueio pelo nome do campo

O nome é normalizado (minúsculas, sem acentos, camelCase separado, separadores convertidos em `_`). Depois, é comparado por token com as categorias abaixo. Assim, "Número do Prontuário", "E-mail" e "patientName" também são bloqueados.

Categoria	Termos bloqueados
CPF	cpf
RG	rg, identidade, registro_geral
CNS	cns, cartao_sus, cartao_nacional_de_saude, cartao_nacional_saude, cartaosus
PRONTUARIO	prontuario, numero_prontuario, medical_record, mrn
TELEFONE	telefone, celular, fone, phone, telephone, mobile, whatsapp
EMAIL	email, mail, correio_eletronico
ENDereco	endereço, logradouro, rua, cep, address, street, zip, zipcode, bairro, complemento

Categoria	Termos bloqueados
NOME	nome, name, full_name, first_name, last_name, sobrenome, nome_completo, nome_social, nome_mae, nome_pai
DATA_NASCIMENTO	data_nascimento, nascimento, birth_date, birthdate, dob, date_of_birth, data_de_nascimento

6.2 Bloqueio pelo conteúdo

As colunas de texto são inspecionadas com as expressões regulares abaixo (aplicadas aos valores distintos e ponderadas pela frequência, o que permite verificar 100.000 linhas em cerca de 1 s):

Padrão	Expressão regular
CPF	(?<![\w.@-])\d{3}\.\d{3}\.\d{3}-\d{2}(?![\w@-])
EMAIL	[\w.+-]+@[[\w-]+\.\d{1,3}]+
TELEFONE	(?<![\w-])(?:\d{2}\d{2})?9?\d{4}-\d{4}(?![\w-])
CEP	(?<![\w-])\d{5}-\d{3}(?![\w-])
IDENTIFICADOR_NUMERICO_LONGO	(?<![\w.-])\d{10,15}(?![\w-])

6.3 Regras de governança

- Todos os registros precisam ter `data_type = SYNTHETIC` e `research_only = true`. Sem isso, o dataset não é conforme e a exportação é bloqueada.
- Uma requisição à API com campo proibido (ex.: `{"cpf": ...}`) recebe HTTP 422. O evento `tentativa_insercao_dado_pessoal` é registrado sem o valor enviado.
- Colunas fora do dicionário de dados geram aviso, para revisão humana.
- Resultado no dataset de exemplo: `compliant = true`, campos bloqueados = nenhum, avisos = nenhum.

6.4 Sintético × anonimizado × pseudonimizado

	Sintético (este projeto)	Anonimizado	Pseudonimizado
Origem	gerado; não há pessoa real	pessoas reais, identificadores removidos	pessoas reais, identificadores trocados por códigos
Reversão	inexistente	não deve ser possível com meios razoáveis	possível com a chave de correspondência
LGPD	não é dado pessoal	não é dado pessoal, salvo se reversível (art. 12)	continua sendo dado pessoal

7. Dataset de exemplo: resultados descritivos

Dataset entregue: **1.000 pacientes**, seed 42, gerado em 2026-10-03. Arquivos: `data/synthetic_dataset.csv` (e `.parquet`), `data/splits/`, `metadata.json`, `dataset_card.md`, `quality_report.md`. Partições: treino 699, validação 150, teste 151.

Variável	Média	DP	Mín	Mediana	Máx
idade	48,70	14,80	18,00	49,00	89,00
peso_kg	68,98	13,96	39,10	67,65	121,20
altura_cm	165,65	9,06	145,00	165,10	190,20
imc	25,08	4,32	16,49	24,84	39,04
pa_sistolica	118,22	14,22	85,00	117,00	163,00
pa_diastolica	71,50	9,52	50,00	71,00	100,00

Variável	Média	DP	Mín	Mediana	Máx
frequencia_cardiaca	74,20	10,46	45,00	74,00	114,00
glicemia_jejum	93,90	19,35	60,00	90,60	219,10
hba1c	4,92	0,75	4,00	4,80	9,20
colesterol_total	193,33	30,67	110,00	193,20	304,70
ldl	117,61	33,11	30,00	117,55	226,50
hdl	50,50	10,80	20,00	50,50	90,90
triglicerides	126,49	54,84	35,00	115,40	539,30
creatinina	0,89	0,21	0,40	0,87	2,56
escore_risco	22,88	22,33	0,50	14,55	95,50

Sexo feminino: 52,5%. Classificação de risco: baixo 39,5%, moderado 19,8%, alto 21,5%, muito alto 19,2%. Desfecho adverso em 12 meses: 13,3%. Pacientes sem condição crônica: 48,5%.




Figura 2 — Distribuições das principais variáveis do dataset de exemplo (n = 1.000, seed 42).




Figura 3 — Relações induzidas pelo modelo causal: a PA sistólica cresce com a idade, a glicemia é maior em quem tem diabetes, e a taxa de desfecho adverso cresce com a classe de risco.

8. Experimentos de aprendizado de máquina

O script `scripts/baseline_experiment.py` usa as partições fixas: treino para ajustar, validação para escolher o limiar de decisão e teste usado uma única vez, ao final. Pré-processamento em *Pipeline* (padronização z-score e one-hot ajustados só no treino). Para evitar vazamento de alvo, alvos e variáveis derivadas deles foram excluídos dos preditores (escore, classe de risco, diagnóstico, resultado e desfecho). Na regressão da PAS, a PAD também foi excluída, porque é gerada a partir da PAS.

8.1 Métricas utilizadas

Seja VP, FP, VN e FN a matriz de confusão; p_i a probabilidade prevista; y_i o rótulo real; $\hat{y}_i$ a previsão; K o número de classes.

$$\begin{aligned} \text{Precisao} &= \frac{VP}{VP + FP} & \text{Sensibilidade} &= \frac{VP}{VP + FN} & F_1 &= \frac{2 \cdot \text{Prec} \cdot \text{Sens}}{\text{Prec} + \text{Sens}} \\ \text{Acuracia balanceada} &= \frac{1}{K} \sum_{k=1}^K \text{Sens}_k & \text{macro } F_1 &= \frac{1}{K} \sum_{k=1}^K F_{1,k} & \text{Brier} &= \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2 \\ \text{ROC AUC} &= P(\hat{S}_+ > \hat{S}_-) & \text{PR AUC (AP)} &= \sum_n (R_n - R_{n-1}) P_n \\ \text{MAE} &= \frac{1}{N} \sum |y_i - \hat{y}_i| & \text{RMSE} &= \sqrt{\frac{1}{N} \sum (y_i - \hat{y}_i)^2} & R^2 &= 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2} \end{aligned}$$

8.2 Resultados com 10.000 pacientes (seed 42, conjunto de teste)

Classificação binária — desfecho_adverso (prevalência no teste: 12,9%)

Modelo	ROC-AUC	PR-AUC	F1	Acur. balanceada	Brier
Dummy (classe majoritária)	0,500	0,129	0,228	0,500	0,112
Regressão logística	0,781	0,384	0,372	0,631	0,185
Random Forest	0,794	0,401	0,407	0,658	0,108

Classificação multiclasse — classificacao_risco

Modelo	Acurácia	Macro-F1	Acur. balanceada	Macro-F1 (validação)
Dummy (classe majoritária)	0,373	0,136	0,250	0,136
Regressão logística multinomial	0,799	0,775	0,776	0,792
Random Forest	0,724	0,667	0,676	0,669

Regressão — pa_sistolica (mmHg)

Modelo	MAE	RMSE	R²	R² (validação)
Dummy (média)	11,52	14,51	0,000	0,000
Ridge	8,07	10,18	0,508	0,484
Random Forest	8,23	10,36	0,491	0,474

8.3 Resultados com 1.000 pacientes (dataset de exemplo)

Modelo	ROC-AUC	PR-AUC	F1	Acur. balanceada	Brier
Dummy (classe majoritária)	0,500	0,152	0,264	0,500	0,130
Regressão logística	0,626	0,367	0,378	0,625	0,200
Random Forest	0,610	0,319	0,379	0,645	0,135

Com só 151 pacientes no teste, as métricas variam mais (por exemplo, a ROC-AUC do desfecho cai de cerca de 0,79 para cerca de 0,62). Isso ilustra o efeito do tamanho amostral: para conclusões estáveis, recomenda-se ≥ 10.000 pacientes e repetição com vários seeds.

8.4 Interpretação

- Todos os modelos superam com folga as baselines ingênuas (classe majoritária ou média), o que confirma que o dataset contém relações aprendíveis.
- O desempenho não é perfeito porque cada etapa do gerador tem ruído, como em dados observacionais. Isso evita um problema artificialmente trivial.
- Na classificação de risco, a regressão logística supera o Random Forest, o que é coerente com o escore ser uma função logística de combinação linear.
- Os números medem a capacidade de recuperar a estrutura do gerador e **não têm validade clínica**.

9. Base pública real e comparação

Para ter uma referência em dados reais, foi incluída, **em separado**, a base **UCI Heart Disease — Cleveland**. Cleveland Clinic Foundation (pesquisador responsável: Robert Detrano, M.D., Ph.D.), coleta de 1988. São 303 pacientes e 14 atributos clínicos, com licença Creative Commons Attribution 4.0 International (CC BY 4.0). Segundo a documentação do repositório (heart-disease.names), nomes e números de seguridade social dos pacientes foram removidos e substituídos por valores fictícios. O arquivo processado contém apenas 14 atributos clínicos, sem identificadores.

Citação: Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1989). Heart Disease [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C52P4X>

9.1 Procedimento

- Download do pacote oficial da UCI e verificação de integridade por SHA-256 do arquivo `processed.cleveland.data` (a74b7efa387bc9d108d7d0115d831fe9b414b29ae7124f331b622b4efa0427c8).
- Renomeação das 14 colunas para português e decodificação das categorias numéricas em rótulos.
- Valores '?' tratados como ausentes (`n_vasos_fluoroscopia` e `cintilografia_talio`).
- Criação de `registro_id` sequencial próprio, de `doenca_cardiaca` (`grau_doenca > 0`) e das colunas de marcação.
- Nenhum registro foi alterado, removido, combinado com outra fonte ou enriquecido.
- Marcação `data_type = REAL_PUBLIC_ANONYMIZED`. Os arquivos ficam em `data/real_public/` e nunca são concatenados ao sintético. O `privacy_guard` aprova a base com a marcação dela e a **recusa** se ela for validada como sintética.
- Qualidade: 303 registros, 297 completos, ausentes {'`n_vasos_fluoroscopia`': 4, '`cintilografia_talio`': 2}, prevalência de doença cardíaca 45,9%. A distribuição dos graus (164/55/36/35/13) confere exatamente com a documentação da UCI.

9.2 Medidas de comparação

$$\text{SMD} = \frac{\bar{X}_S - \bar{X}_R}{\sqrt{(s_S^2 + s_R^2)/2}} \quad D_{KS} = \sup_x |F_S(x) - F_R(x)| \quad W_1 = \int_{-\infty}^{\infty} |F_S(x) - F_R(x)| dx$$

$$z = \frac{\hat{p}_S - \hat{p}_R}{\sqrt{\hat{p}(1-\hat{p})(\frac{1}{n_S} + \frac{1}{n_R})}}, \quad \hat{p} = \frac{x_S + x_R}{n_S + n_R}$$

SMD é a diferença média padronizada ($|\text{SMD}| \geq 0,2$ pequena; $\geq 0,5$ média; $\geq 0,8$ grande). D_{KS} é a estatística de Kolmogorov-Smirnov para duas amostras. W_1 é a distância de Wasserstein-1, na unidade da variável. z é o teste de duas proporções com variância agrupada.

9.3 Resultados

Variável	Sintético média (DP)	Real média (DP)	SMD	KS D	KS p	W_1
Idade (anos)	48,7 (14,8)	54,4 (9,0)	-0,47	0,234	1.2e-11	7,2
PA sistólica (mmHg)	118,2 (14,2)	131,7 (17,6)	-0,84	0,379	2.3e-30	13,5
Colesterol total (mg/dL)	193,3 (30,7)	246,7 (51,8)	-1,25	0,508	1.9e-55	53,4

Variável	Sintético	Real	z	p
Sexo masculino	47,5%	68,0%	-6,25	4.0e-10
Glicemia de jejum > 120 mg/dL	5,2%	14,9%	-5,61	2.1e-08




Figura 4 — Distribuições em comum: sintético (azul, $n = 1.000$) × real UCI (vermelho, $n = 303$).

Modelos na base real — alvo doença cardíaca (grau > 0); 5-fold estratificado repetido 10x (50 ajustes por modelo). Média (desvio padrão):

Modelo	ROC-AUC	Acurácia	F1	Acur. balanceada
Dummy (classe majoritária)	0,500 (0,000)	0,541 (0,005)	0,000 (0,000)	0,500 (0,000)
Regressão logística	0,910 (0,032)	0,838 (0,040)	0,816 (0,045)	0,834 (0,040)
Random Forest	0,910 (0,034)	0,828 (0,050)	0,807 (0,056)	0,825 (0,050)

9.4 Interpretação

As diferenças são **esperadas e não indicam defeito**. O gerador não foi calibrado com esta base (por decisão metodológica, nenhum dado real foi usado como molde), e a amostra UCI é de pacientes encaminhados para angiografia nos EUA em 1988, mais velhos, majoritariamente homens e com colesterol mais alto. Com amostras deste tamanho, o teste KS rejeita a igualdade mesmo para diferenças moderadas. Assim, a comparação quantifica o *domain shift* entre os dados de desenvolvimento e um cenário real. Os modelos treinados na base real (ROC-AUC ≈ 0,91) servem de referência de desempenho em dados reais para a pesquisa.

Por que não o DATASUS. Os microdados do DATASUS também são públicos e anonimizados, mas são distribuídos em formato .dbc, exigem bibliotecas nativas adicionais e têm volume muito maior. A base UCI tem licença explícita, tamanho adequado, variáveis clínicas em comum e ampla citação na literatura de ML. O DATASUS fica como extensão futura.

10. Testes automatizados

A suíte pytest tem **186 testes**. Resultado da execução durante a geração deste relatório: **186 aprovados, nenhuma falha**.

Arquivo	Testes	O que verifica
test_api.py	18	fluxo completo do painel, exportação, validação de entrada, bloqueio de dados pessoais via API
test_bmi.py	11	IMC com valores conhecidos, entradas inválidas, versão vetorizada, consistência no dataset
test_export.py	13	4 formatos gravam e relêem os mesmos dados; exportação bloqueada sem gravar arquivo; splits
test_generator.py	20	quantidade, colunas, marcações, reprodutibilidade por seed, unicidade de IDs, distribuições, relações causais, split 70/15/15 estratificado
test_integrity.py	6	ida e volta banco ↔ DataFrame idêntica, contagens por tabela, substituição atômica, auditoria, metadados
test_privacy.py	92	21 variações de campos proibidos, ausência de falso positivo, conteúdo sensível, marcação SYNTHETIC, logs sem valores
test_public_dataset.py	9	conversão da base UCI, ausentes, alvo derivado, SHA-256, privacidade, separação, distribuição de classes oficial
test_quality.py	17	cada defeito injetado é detectado (ausentes, faixas, IMC, PA, duplicidade, tipos, datas, categorias, consistência)

Durante o desenvolvimento, os testes revelaram e permitiram corrigir um defeito real: a geração repetida com o mesmo seed violava a chave primária, porque o dataset anterior era removido depois da inserção do novo. A ordem foi invertida dentro da mesma transação.

11. Reprodutibilidade

Comandos para reproduzir todos os artefatos deste relatório, a partir da raiz do projeto:

```
python scripts/generate_dataset.py --n 1000 --seed 42 --formats csv,parquet
python scripts/quality_report.py --input data/synthetic_dataset.csv
python scripts/baseline_experiment.py --input data/synthetic_dataset.csv --seed 42
python scripts/generate_dataset.py --n 10000 --seed 42 --out data/experimentos/n10000_seed42
--no-splits
python scripts/baseline_experiment.py --input data/experimentos/n10000_seed42/synthetic_dataset.csv
python scripts/fetch_public_dataset.py
python scripts/compare_synthetic_real.py
python -m pytest
python scripts/build_report_pdf.py
```

- Versões de todas as dependências fixadas em backend/requirements.txt e frontend/package-lock.json.
- Seeds: 42 para os dados e os modelos; o split usa seed + 7919.
- Identificação do dataset de exemplo: dataset_id c78e1dac-cc03-4759-8c05-976c472b9f8d, versão 1.0.0, gerador 1.0.0.
- Ambiente: Python 3.12 e Node.js 20+; opcionalmente docker compose up --build.

12. Limitações e riscos

- Os dados são inteiramente sintéticos: não representam nenhuma população real e não servem para estimar prevalências, riscos ou efeitos de tratamento reais.
- Os coeficientes do modelo de geração foram escolhidos para produzir valores plausíveis, não estimados de estudos clínicos; relações entre variáveis são simplificadas.
- O `escore_risco` e a `classificacao_risco` são construções sintéticas e NÃO equivalem a escores clínicos validados (ex.: Framingham, SCORE2).
- Variáveis independentes entre si no gerador (ex.: estado, municipio, data_atendimento) não carregam sinal preditivo.
- Não há séries temporais longitudinais: cada paciente possui um único atendimento fictício.
- Modelos treinados apenas com estes dados não devem ser usados em decisões clínicas nem considerados validados para uso real.
- Desempenho de modelos neste dataset reflete a estrutura do gerador; resultados precisam ser validados em dados reais devidamente autorizados antes de qualquer conclusão clínica.
- Risco de interpretar resultados como evidência clínica. Mitigação: avisos permanentes no painel, nos arquivos e neste relatório.
- Risco de vazamento de alvo. Mitigação: lista explícita de variáveis derivadas, excluídas nos experimentos.
- A base real UCI é pequena (303), de um único centro, de 1988 e com viés de seleção. Não representa a população brasileira.

13. Referências

AUSTIN, P. C. Balance diagnostics for comparing the distribution of baseline covariates between treatment groups in propensity-score matched samples. *Statistics in Medicine*, v. 28, n. 25, p. 3083–3107, 2009.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD).

DETRANO, R. et al. International application of a new probability algorithm for the diagnosis of coronary artery disease. *American Journal of Cardiology*, v. 64, n. 5, p. 304–310, 1989.

FRIEDEWALD, W. T.; LEVY, R. I.; FREDRICKSON, D. S. Estimation of the concentration of low-density lipoprotein cholesterol in plasma, without use of the preparative ultracentrifuge. *Clinical Chemistry*, v. 18, n. 6, p. 499–502, 1972.

GEBRU, T. et al. Datasheets for datasets. *Communications of the ACM*, v. 64, n. 12, p. 86–92, 2021.

JANOSI, A.; STEINBRUNN, W.; PFISTERER, M.; DETRANO, R. Heart Disease [Dataset]. UCI Machine Learning Repository, 1989. <https://doi.org/10.24432/C52P4X>.

NATHAN, D. M. et al. Translating the A1C assay into estimated average glucose values. *Diabetes Care*, v. 31, n. 8, p. 1473–1478, 2008.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

WORLD HEALTH ORGANIZATION. Obesity: preventing and managing the global epidemic. WHO Technical Report Series 894. Geneva: WHO, 2000.